Business Intelligence

Proyecto final · Entrega 3

Modelo predictivo

MoviBogotá S.A. · Pronóstico de demanda por estación

Integrante	Código
David Santiago Prieto Beltrán	506212024
Naren Santiago Rojas Sánchez	506232716
Joseph David Vargas Olaya	506232072

Dato	Valor
Docente	Leandro Pájaro Fuentes
Fecha de entrega	13/11/2026
Repositorio	https://github.com/Narens-dev/bi-proyecto-equipo506232716
Entorno del modelo	Python 3.13 en Jupyter (pandas 3.0, scikit-learn 1.9, SQLAlchemy 2.1)

Resumen de la entrega

La pregunta P3 pide anticipar **cuántas validaciones tendrá cada estación en cada mes del próximo trimestre**, para repartir la flota y las frecuencias entre troncales. El modelo predice las validaciones de una estación en un mes usando solo lo que se sabe tres meses antes (su historia, su tipo, su troncal y el calendario).

Se entrenaron una regresión lineal y un bosque aleatorio con los mismos datos del data warehouse (106 estaciones, jun 2024 – sep 2025) y se probaron en oct–dic 2025. Se eligió la **regresión lineal**: **MAE de 4,29 validaciones por estación y mes** (RMSE 5,90), por debajo de la meta de 5 y del pronóstico ingenuo (6,10).

Respuesta: para **enero–marzo de 2026 el modelo pronostica 6.894 validaciones** (+3,2 % frente a ene–mar de 2025). Autopista Norte concentra el 18,5 % (1.275), por lo que le corresponderían unos 83 de los 450 buses, 21 más de los 62 que opera hoy la ruta B12.

1. Comprensión del negocio

1.1 Pregunta y decisión

P3 (nueva, reformulada): ¿Cuántas validaciones se esperan por estación en cada mes del próximo trimestre? La P3 de la tabla 1.3 de la Entrega 1 preguntaba por la probabilidad de fallas técnicas de los buses, pero el inventario no tiene datos de mantenimiento ni de kilómetros recorridos, así que no se puede entrenar ese modelo. En la Entrega 2 la P3 quedó como pronóstico de demanda por estación y franja; aquí se trabaja por estación y mes porque, al cruzar estación con franja, cada celda tiene en promedio unas 4 validaciones al mes y el error quedaría dominado por el ruido. Sigue siendo la misma decisión de negocio de las preguntas P0–P2. **Decisión:** antes de cada trimestre, la Gerencia de Operaciones reparte los 450 buses y las frecuencias entre las 7 rutas troncales según la demanda pronosticada de sus estaciones.

1.2 Variable objetivo y tipo de problema

Elemento	Respuesta
Variable objetivo	validaciones: número de validaciones de una estación en un mes (suma de fact_validaciones.cantidad_validaciones)
Tipo de problema	Regresión
Unidad de predicción	Una predicción por estación y mes (106 estaciones con demanda)

1.3 Criterio de éxito

MAE menor a 5 validaciones por estación y mes en el conjunto de prueba (oct–dic 2025) y, además, menor que el MAE del pronóstico ingenuo (repetir el valor de la misma estación de hace 3 meses). Cinco validaciones equivalen a menos de un cuarto de la demanda media de una estación (21,5 al mes). Si los dos algoritmos quedan a menos de 0,1 de MAE, se elige el de menor RMSE.

2. Comprensión de los datos

2.1 Consulta de extracción

Archivo modelo/extraccion.sql (el notebook lo lee y lo ejecuta con SQLAlchemy contra movibogota_dw):

```
-- Entrega 3 · Extracción del conjunto de datos para el modelo predictivo (pregunta P3)
-- Una fila por estación y mes: 106 estaciones con demanda × 24 meses de 2024–2025 = 2.544 filas.
-- Une fact_validaciones con dim_tiempo (mes del hecho) y dim_estacion (atributos de la estación).
-- La malla estación × mes se arma con CROSS JOIN para que los meses sin validaciones queden con 0.
-- Filtra: (1) la estación desconocida (sk_estacion = -1), que no tiene atributos para el modelo, y
--         (2) las 47 estaciones sin ninguna validación en 2024–2025 (troncales que no cubren las 7
rutas
--         de MoviBogotá): su demanda es siempre 0 y solo inflarían los aciertos del modelo.
```

```
WITH meses AS (
    SELECT anio, mes,
           MIN(sk_tiempo)                                  AS sk_tiempo_mes,   -- primer día del mes
           COUNT(*)                                        AS dias_mes,
           COUNT(*) FILTER (WHERE NOT es_fin_semana)       AS dias_habiles
    FROM dw.dim_tiempo
    WHERE sk_tiempo > 0
      AND sk_tiempo <= (SELECT MAX(sk_tiempo) FROM dw.fact_validaciones)   -- sin los meses del
horizonte
    GROUP BY anio, mes
),
hechos AS (
    SELECT f.sk_estacion, t.anio, t.mes,
           SUM(f.cantidad_validaciones)                                    AS validaciones,
           SUM(f.cantidad_validaciones) FILTER (WHERE h.es_hora_pico)      AS validaciones_pico
    FROM dw.fact_validaciones f
    JOIN dw.dim_tiempo t ON t.sk_tiempo = f.sk_tiempo
    JOIN dw.dim_hora   h ON h.sk_hora   = f.sk_hora
    WHERE f.sk_estacion > 0
    GROUP BY f.sk_estacion, t.anio, t.mes
)
SELECT e.sk_estacion,
       m.sk_tiempo_mes                      AS sk_tiempo,
       e.cod_estacion,
       e.nombre_estacion,
       e.nombre_troncal,
       e.tipo_estacion,
       e.num_vagones,
       e.num_accesos,
       e.area_m2,
       m.anio,
       m.mes,
       m.dias_mes,
       m.dias_habiles,
       COALESCE(hc.validaciones, 0)         AS validaciones,
       COALESCE(hc.validaciones_pico, 0)    AS validaciones_pico
FROM dw.dim_estacion e
CROSS JOIN meses m
LEFT JOIN hechos hc
       ON hc.sk_estacion = e.sk_estacion AND hc.anio = m.anio AND hc.mes = m.mes
WHERE e.sk_estacion > 0
  AND e.sk_estacion IN (SELECT sk_estacion FROM hechos)
ORDER BY e.sk_estacion, m.anio, m.mes;
```

Qué une: fact_validaciones con dim_tiempo (para agrupar por mes) y dim_hora (para separar las validaciones en hora pico); el resultado se cruza con dim_estacion (atributos de la estación) mediante una malla estación × mes, para que los meses sin validaciones queden en 0. **Qué filtra:** la estación desconocida (llave −1, 38 validaciones sin atributos), las 47 estaciones sin ninguna validación en 2024–2025 (están en troncales que no recorren las 7 rutas de MoviBogotá; su demanda es siempre 0 y solo inflarían los aciertos) y los meses de la dimensión de tiempo posteriores al último hecho.

2.2 Descripción del conjunto de datos

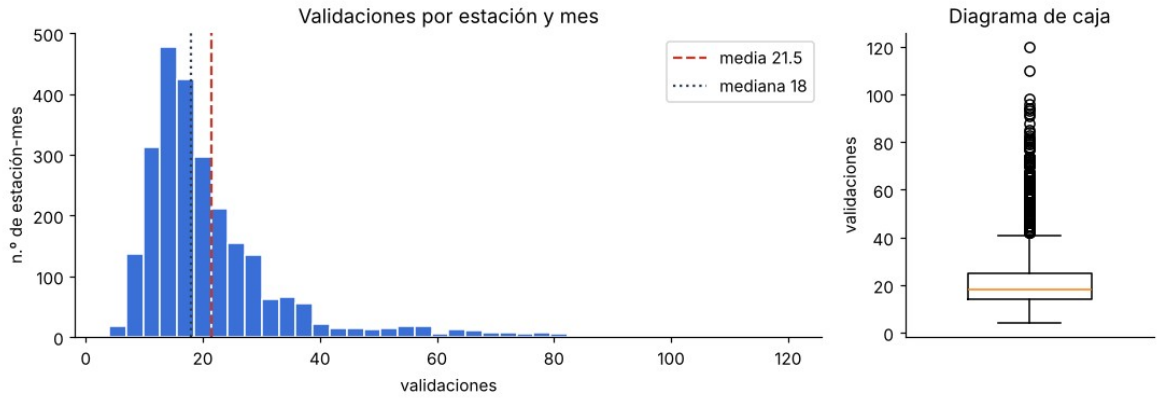
2.544 registros (106 estaciones × 24 meses), de **enero de 2024 a diciembre de 2025**; suman 54.737 validaciones (las 54.775 del DW menos las 38 de la estación desconocida).

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
validaciones	Numérica	Objetivo	fact_validaciones.cantidad_validaciones (SUM)	Validaciones de la estación en el mes
sk_estacion	Entera	Llave	dim_estacion.sk_estacion	Identifica la estación; une la predicción a la dimensión
sk_tiempo / anio / mes	Entera	Llave y entrada (mes)	dim_tiempo.sk_tiempo, anio, mes	Primer día del mes; el mes (1–12) captura la estacionalidad
dias_habiles	Entera	Entrada	dim_tiempo.es_fin_semana (conteo)	Días de lunes a viernes del mes

Variable	Tipo	Papel	Origen (tabla.columna)	Descripción
validaciones_pico	Numérica	Insumo de variable derivada	fact_validaciones + dim_hora.es_hora_pico	Validaciones del mes en 05:00–08:59 y 16:00–19:59
tipo_estacion	Categórica (4)	Entrada	dim_estacion.tipo_estacion	Portal, Intermedia, Temporal o Sencilla
nombre_troncal	Categórica (7)	Entrada	dim_estacion.nombre_troncal	Troncal donde está la estación
num_vagones, num_accesos	Entera	Entrada	dim_estacion.num_vagones, num_accesos	Tamaño físico de la estación
area_m2	Numérica	Entrada	dim_estacion.area_m2	Área de la estación (264 registros nulos)
dias_mes, cod_estacion, nombre_estacion	Entera / texto	Descriptiva (no entra al modelo)	dim_tiempo, dim_estacion	Para reportes y para el tablero

2.3 Distribución de la variable objetivo

Las validaciones por estación y mes van de **4 a 120**, con media 21,5, mediana 18 y desviación estándar 13,3. La distribución es asimétrica a la derecha: la mitad de las estaciones-mes está entre 14 y 25. Por el criterio del rango intercuartílico (más de 41,5) hay **169 registros atípicos (6,6 %)**; casi todos son de los 7 portales (Portal Norte, El Dorado y Américas los 24 meses), que de verdad tienen más demanda, por eso se conservan.



2.4 Análisis exploratorio

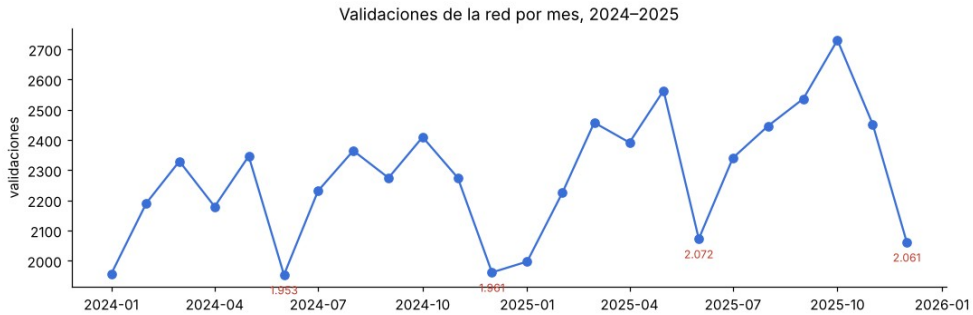


Gráfico 1. Tendencia mensual de la red. La demanda crece de 26.467 validaciones en 2024 a 28.270 en 2025 (+6,8 %) y baja todos los años en junio y diciembre (vacaciones). El modelo necesita el mes del año y una referencia de nivel reciente de cada estación.

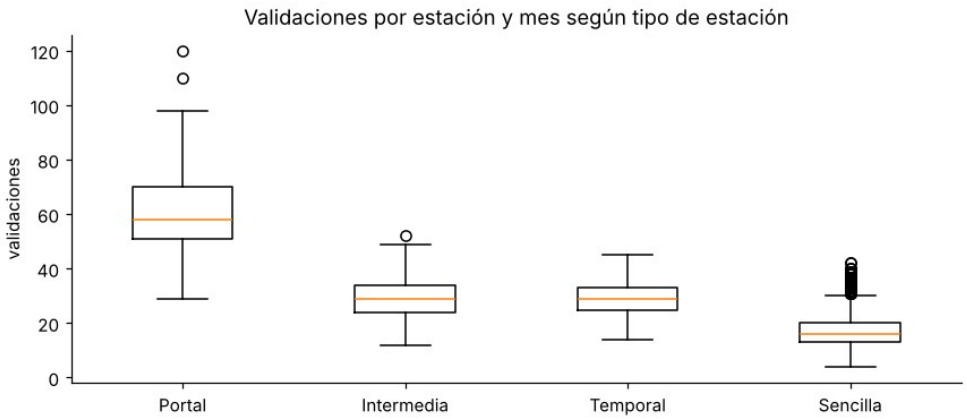


Gráfico 2. Tipo de estación. Un portal tiene una mediana de 58 validaciones al mes, frente a 29 en las intermedias y temporales y 16 en las sencillas: el tipo de estación separa bien los niveles de demanda.

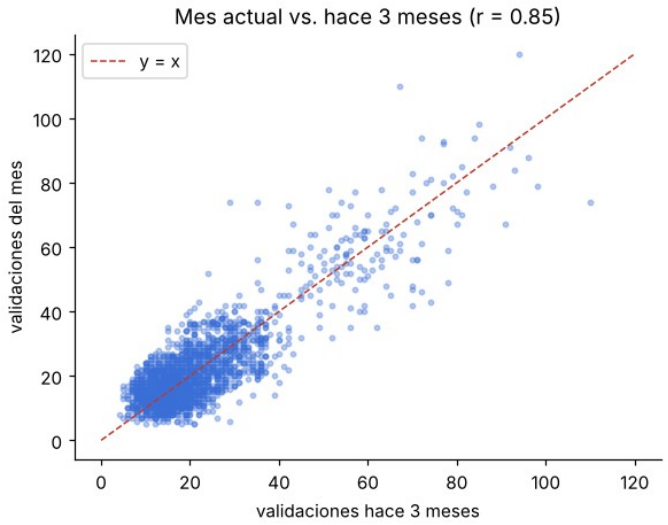


Gráfico 3. Demanda de hace 3 meses. Las validaciones de un mes tienen una correlación de 0,85 con las de la misma estación tres meses antes; la nube sigue la diagonal, pero se abre en las estaciones grandes, donde el error será mayor.

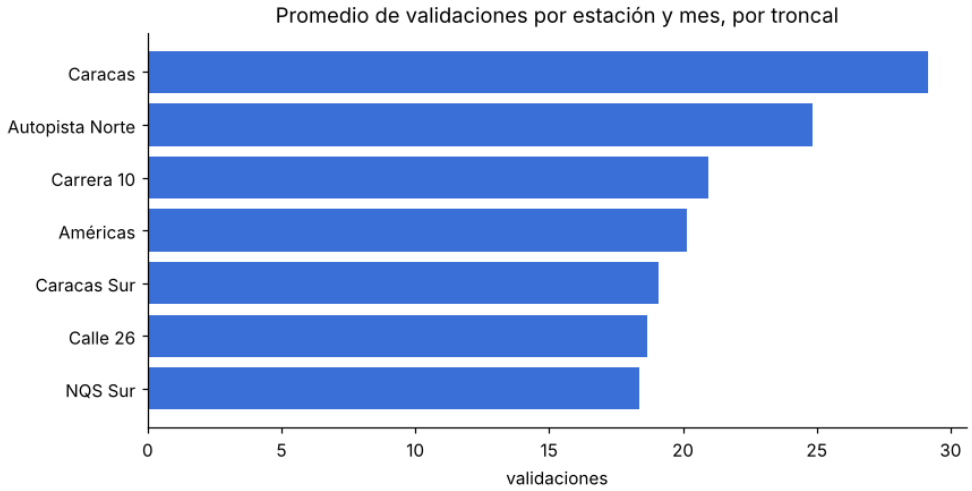


Gráfico 4. Troncal. Las estaciones de Caracas (29,1 al mes) y Autopista Norte (24,9) tienen más demanda que las de NQS Sur (18,4) o Calle 26 (18,7).

3. Preparación de los datos

3.1 Limpieza y transformación

Tratamiento	Variable(s)	Qué se hizo	Registros afectados
Nulos	area_m2	Se imputó la mediana del área de su tipo de estación	264 (11 estaciones × 24 meses)
Atípicos	validaciones	Se identificaron con el rango intercuartílico (> 41,5) y se conservaron: son meses reales de los portales	169
Filtrado	Estaciones sin demanda	Se excluyeron las estaciones sin ninguna validación en 2024–2025 (en la consulta SQL)	1.128 (47 estaciones × 24 meses)
Filtrado	Meses sin historia	Se excluyeron ene–may 2024: no tienen el rezago de 5 meses	530
Codificación categórica	tipo_estacion, nombre_troncal	One-hot encoding (OneHotEncoder): 4 + 7 columnas de 0/1, sin orden implícito entre categorías	—
Escalado	Variables numéricas	Estandarización (StandardScaler): media 0 y desviación 1, ajustada solo con el entrenamiento	—

3.2 Variables derivadas

Todas se calculan con datos de tres o más meses antes del mes que se predice, así que al empezar un trimestre ya se conocen para sus tres meses.

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
lag_3, lag_4, lag_5	Validaciones de la misma estación 3, 4 y 5 meses antes	La demanda reciente anticipa la siguiente (r = 0,85)	Sí: 3 o más meses antes

Variable nueva	Cómo se calcula	Por qué puede ayudar	¿Se conoce antes del hecho?
media_lag_3a5	Promedio de lag_3, lag_4 y lag_5	Suaviza los meses atípicos	Sí
media_historica	Promedio de todos los meses de la estación hasta t − 3	Nivel estable de la estación	Sí
participacion_pico_hist	Validaciones en hora pico / validaciones totales de la estación, hasta t − 3	Diferencia estaciones de paso de las de destino	Sí
dias_habiles	Días de lunes a viernes del mes	Los meses con más días hábiles tienen más viajes	Sí: es calendario

3.3 División en entrenamiento y prueba

Conjunto	Registros	Periodo o proporción
Entrenamiento	1.696	Junio 2024 – septiembre 2025 (16 meses × 106 estaciones)
Prueba	318	Octubre – diciembre 2025 (3 meses; 15,8 % del total)
Pronóstico (sin valor real)	318	Enero – marzo 2026

4. Modelado

4.1 Algoritmos

Los dos algoritmos se entrenan con el mismo conjunto de entrenamiento (1.696 registros) y las mismas 13 variables de entrada (11 numéricas y 2 categóricas), con el mismo preprocesamiento (ColumnTransformer: StandardScaler + OneHotEncoder) dentro de un Pipeline de scikit-learn. Como referencia se calcula también el pronóstico ingenuo (lag_3).

Algoritmo	Por qué se eligió	Parámetros usados
Regresión lineal	Es el modelo base para predecir una cantidad: rápido, sin hiperparámetros y con coeficientes que dicen cuánto suma cada variable	LinearRegression() con valores por defecto (fit_intercept=True)
Bosque aleatorio	Captura relaciones no lineales e interacciones (por ejemplo, tipo de estación × mes) y es robusto a los atípicos de los portales	RandomForestRegressor(n_estimators=300, max_depth=8, min_samples_leaf=5, random_state=42)

5. Evaluación

5.1 Métricas sobre el conjunto de prueba

Regresión

Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Regresión lineal	4,29	5,90	Se equivoca en promedio 4,3 validaciones por estación y mes (19 % de la media de prueba, 22,8). El RMSE de 5,9 muestra errores grandes en los portales (MAE 10,3), sobre todo Portal Norte en octubre (120 reales frente a 80 predichas). En el total de la red el trimestre queda 3,6 % por debajo (6.985 frente a 7.243).
Bosque aleatorio	4,28	6,01	Error promedio prácticamente igual (4,3 validaciones), pero con errores grandes más frecuentes (RMSE 6,0) y un total de la red 6,4 % por debajo de lo real: subestima más los meses altos.

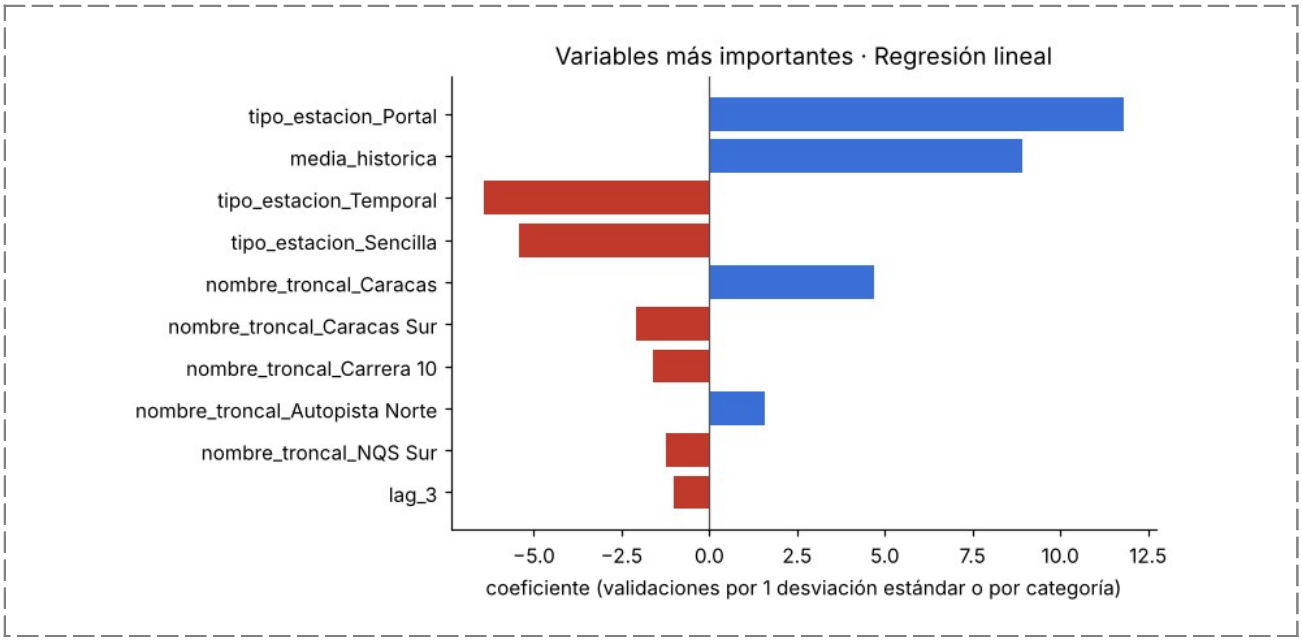
Algoritmo	MAE	RMSE	Interpretación en unidades del caso
Referencia: pronóstico ingenuo (lag_3)	6,10	8,05	Repetir lo de hace 3 meses se equivoca 6,1 validaciones por estación y mes: los dos modelos lo mejoran en un 30 %.

5.2 Comparación y elección

Se elige la **regresión lineal**. Su MAE (4,29) y el del bosque aleatorio (4,28) difieren en solo 0,01 validaciones, un empate práctico; según la regla de la sección 1.3, decide el RMSE, que es 0,11 menor en la regresión lineal (5,90 frente a 6,01). Además, la regresión lineal acierta mejor el total del trimestre (−3,6 % frente a −6,4 %), que es la cifra con la que se reparte la flota, y sus coeficientes se pueden explicar al gerente. Para el pronóstico de ene–mar 2026 se reentrena con todo el periodo conocido (jun 2024 – dic 2025), con los mismos parámetros y variables.

5.3 Variables más importantes

Coeficientes de la regresión lineal (las 10 variables de mayor peso). Ser **portal** es lo que más suma: a igual historia, un portal recibe unas 17 validaciones al mes más que una estación sencilla (+11,8 frente a −5,4). La **media histórica** de la estación es la variable numérica más importante: cada 11,9 validaciones más en su promedio (una desviación estándar) suman 8,9 validaciones al mes pronosticado. La troncal ajusta el nivel (Caracas +4,7, Autopista Norte +1,6; Caracas Sur −2,1), y los rezagos individuales pesan poco porque su información ya está en la media histórica.



5.4 Criterio de éxito

Criterio (sección 1.3)	Valor obtenido	¿Se alcanzó?
MAE < 5 validaciones por estación y mes en oct–dic 2025, y menor que el ingenuo (6,10)	MAE = 4,29 (regresión lineal)	Sí

5.5 Respuesta a la pregunta de negocio

Para **enero–marzo de 2026** el modelo pronostica **6.894 validaciones** en las 106 estaciones (2.269 en enero, 2.264 en febrero y 2.361 en marzo), un 3,2 % más que en el mismo trimestre de 2025 (6.679). Las estaciones con más demanda serán Portal Norte - Unicervantes (241), Portal Américas (201) y Portal El Dorado (188). Por troncal, si los 450 buses se reparten en proporción a la demanda pronosticada:

- **Autopista Norte (B12):** 1.275 validaciones (18,5 %); hoy 62 buses, le corresponderían 83 (+21).
- **Caracas (A60):** 1.240 validaciones (18,0 %); hoy 72 buses, le corresponderían 81 (+9).
- **Américas (F23):** 1.038 validaciones (15,1 %); hoy 70 buses, le corresponderían 68 (−2).
- **Caracas Sur (H27):** 982 validaciones (14,2 %); hoy 60 buses, le corresponderían 64 (+4).
- **NQS Sur (G43):** 943 validaciones (13,7 %); hoy 68 buses, le corresponderían 62 (−6).
- **Calle 26 (K16):** 778 validaciones (11,3 %); hoy 64 buses, le corresponderían 51 (−13).
- **Carrera 10 (L10):** 638 validaciones (9,3 %); hoy 54 buses, le corresponderían 42 (−12).

Decisión que apoya: para el primer trimestre de 2026, Operaciones debería reasignar unos **21 buses a la ruta B12 (Autopista Norte)** y unos 9 a la A60 (Caracas), tomándolos sobre todo de la K16 (Calle 26, 13 buses) y la L10 (Carrera 10, 12 buses). Como el modelo se equivoca en promedio 4,3 validaciones por estación y mes, y hasta 10 en los portales, conviene dejar un margen de buses de reserva en los portales del norte.

6. Despliegue

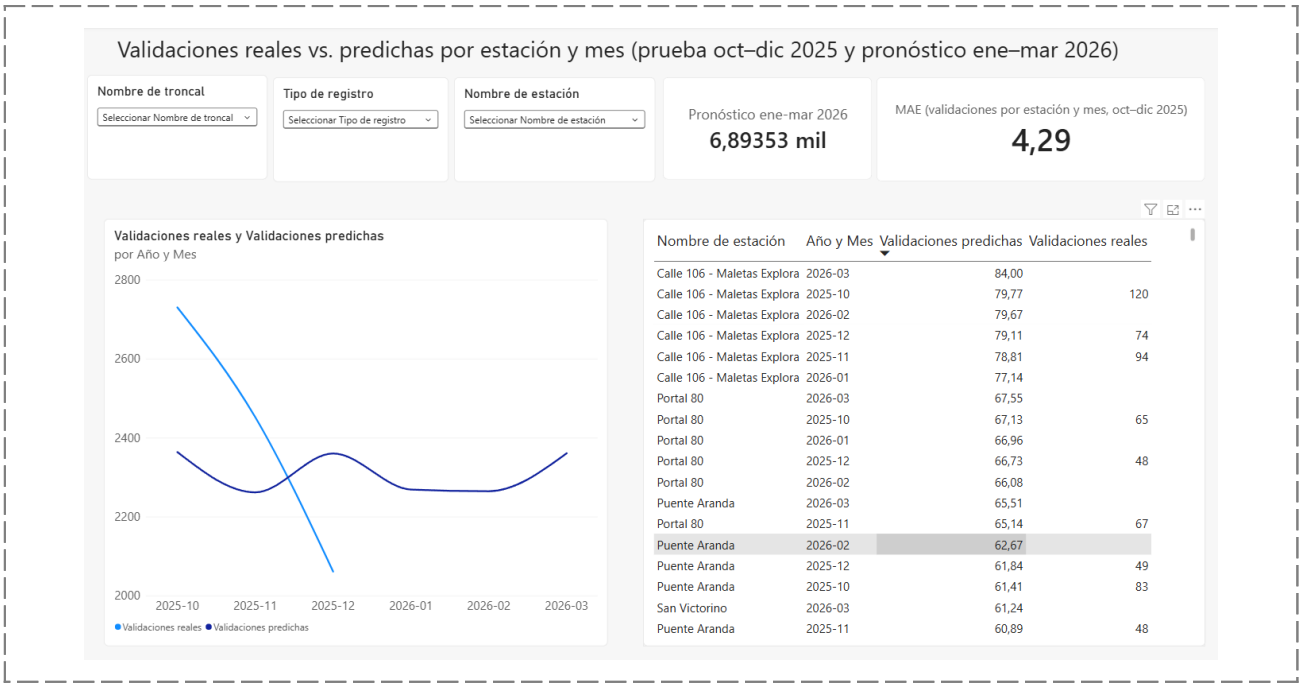
6.1 Tabla de predicciones

Tabla **dw.pred_validaciones_estacion_mes** (script dw/ddl/10_pred_validaciones_estacion_mes.sql), con **636 registros**: 318 de prueba (oct–dic 2025, con valor real y error) y 318 de pronóstico (ene–mar 2026). Llave primaria (sk_estacion, sk_tiempo). El script también extiende dim_tiempo a ene–mar 2026 para que el pronóstico tenga su llave de tiempo, y crea la vista dw.v_tablero_predicciones que usa el tablero. La escribe el notebook y también la carga Pentaho: el trabajo etl/trabajos/j_despliegue_predicciones.kjb ejecuta el script 10 y la transformación t_pred_validaciones.ktr, que lee modelo/predicciones.csv y escribe las 636 filas. Así el despliegue queda en el mismo ETL del resto del data warehouse y funciona aunque el modelo se entrene fuera del servidor del DW. Como j_carga_dw.kjb vacía el DW, este trabajo se ejecuta después de él.

Columna	Tipo	Descripción
sk_estacion	INTEGER	Llave a dim_estacion
sk_tiempo	INTEGER	Llave a dim_tiempo (primer día del mes)
anio, mes	SMALLINT	Año y mes de la predicción
tipo_registro	VARCHAR(12)	'prueba' (oct–dic 2025) o 'pronostico' (ene–mar 2026)
validaciones_reales	INTEGER	Valor real; NULL en el pronóstico
validaciones_predichas	NUMERIC(10,2)	Predicción del modelo elegido
error_absoluto	NUMERIC(10,2)	|real − predicho|, solo en prueba
modelo, fecha_ejecucion	VARCHAR(40), TIMESTAMP	Algoritmo (Regresión lineal) y fecha de la corrida

6.2 Página de predicciones en el tablero

Página «Predicciones» del tablero de Power BI (dashboard/MoviBogota_Tablero.pbix), conectada en modo importar a dw.pred_validaciones_estacion_mes, dw.dim_estacion y dw.dim_tiempo, unidas por sk_estacion y sk_tiempo. El gráfico de líneas compara, mes a mes, el total real y el total predicho de todas las estaciones (prueba oct–dic 2025 y pronóstico ene–mar 2026); en diciembre el total real queda por debajo del predicho, mes en que la demanda baja por vacaciones (sección 2.4). Las tarjetas muestran el pronóstico del trimestre (6.894 validaciones) y el MAE de la prueba (4,29), y la tabla da el detalle por estación y mes. Tiene tres filtros desplegables: troncal (nombre_troncal), tipo de registro (prueba o pronóstico) y estación (nombre_estacion).


Validaciones reales vs. predichas por estación y mes (prueba oct–dic 2025 y pronóstico ene–mar 2026)
Nombre de troncal
Seleccionar Nombre de troncal
Tipo de registro
Seleccionar Tipo de registro
Nombre de estación
Seleccionar Nombre de estación
Pronóstico ene-mar 2026
6,89353 mil
MAE (validaciones por estación y mes, oct–dic 2025)
4,29
Validaciones reales y Validaciones predichas
por Año y Mes
2800
2600
2400
2200
2000
2025-10
2025-11
2025-12
2026-01
2026-02
2026-03
Validaciones reales
Validaciones predichas
Nombre de estación
Año y Mes
Validaciones predichas
Validaciones reales
Calle 106 - Maletas Explora 2026-03 84,00
Calle 106 - Maletas Explora 2025-10 79,77 120
Calle 106 - Maletas Explora 2026-02 79,67
Calle 106 - Maletas Explora 2025-12 79,11 74
Calle 106 - Maletas Explora 2025-11 78,81 94
Calle 106 - Maletas Explora 2026-01 77,14
Portal 80 2026-03 67,55
Portal 80 2025-10 67,13 65
Portal 80 2026-01 66,96
Portal 80 2025-12 66,73 48
Portal 80 2026-02 66,08
Puente Aranda 2026-03 65,51
Portal 80 2025-11 65,14 67
Puente Aranda 2026-02 62,67
Puente Aranda 2025-12 61,84 49
Puente Aranda 2025-10 61,41 83
San Victorino 2026-03 61,24
Puente Aranda 2025-11 60,89 48